

Predicción de cancelación (churn) y segmentación de clientes:

Caso Telmex Claro

Gabriel David Rincón Bohórquez

Julian Esteban Ruiz Benavides

Orladis Muñoz Gómez

Universidad Piloto de Colombia

Especialización en Inteligencia Artificial

Aprendizaje de Máquina

Docente Cristian Camilo Tirado Cifuentes

06 de febrero de 2026

Resumen

Este proyecto presenta un modelo de aprendizaje de máquina para la predicción de cancelación (churn) de clientes en el sector de telecomunicaciones, tomando como caso de estudio Telmex Claro. El objetivo principal es desarrollar dos modelos supervisados para anticipar cancelaciones en ventanas de 30 y 60 días, junto con una segmentación no supervisada utilizando K-Means. El documento describe la formulación del proyecto, el procesamiento de datos, la selección de algoritmos, la evaluación del rendimiento y las recomendaciones finales.

Tabla de contenido

Planeación y formulación del proyecto	5
Contexto del problema	5
Objetivo general	5
Objetivos específicos	6
Alcance.....	6
Cronograma	7
Estructura de descomposición del trabajo (EDT/WBS)	7
Plan de comunicaciones.....	8
Equipo requerido (Roles).....	8
Recursos	8
Presupuesto estimado	9
Riesgos y mitigaciones	9
Recopilación y preparación de datos	11
Fuentes de datos	11
Definición de la variable objetivo (Target)	11
Diccionario de variables	11
Preprocesamiento.....	12
Selección de algoritmos y técnicas apropiadas	13
Componente supervisado: Clasificación de churn	13
Componente no supervisado: K-Means clustering.....	14
Evaluación de rendimiento y ajuste del modelo	15
Resultados del modelo churn_30	15
Resultados del modelo churn_60	16
Importancia de variables (Random Forest).....	17
Perfiles de clusters (K-Means)	17
Selección de K y validación del clustering.....	18
Conclusiones y recomendaciones.....	19

Conclusiones del proyecto.....	19
Recomendaciones	19
Matriz de acciones por segmento	20
Aporte en prospectiva	20
Referencias.....	22

Planeación y formulación del proyecto

Contexto del problema

En el negocio de servicios de telecomunicaciones (caso Telmex Claro), la cancelación de clientes (churn) representa una pérdida directa de ingresos y un aumento significativo del costo de adquisición de nuevos usuarios. La cancelación no ocurre de manera aleatoria: suele estar asociada con variables observables como:

- Quejas y tickets técnicos: Clientes con problemas de servicio recurrentes.
- Mora y comportamiento de pago: Historial de pagos tardíos o impagos.
- Antigüedad del cliente: Clientes nuevos tienden a tener mayor riesgo.
- Tipo de contrato: Contratos mensuales vs. contratos a término.
- Estacionalidad: En períodos como enero y febrero aumenta debido a presión competitiva.

Por lo tanto, se plantea un proyecto de aprendizaje de máquina para anticipar la probabilidad de churn y, además, segmentar clientes para diseñar intervenciones diferenciadas de retención.

Objetivo general

Diseñar e implementar un proyecto de aprendizaje de máquina que integre: (1) un modelo supervisado para predecir la probabilidad de churn en ventanas de 30 y 60 días (dos modelos separados según recomendación del profesor), y (2) una técnica no supervisada (K-Means) para segmentar clientes y caracterizar perfiles de riesgo, con el fin de apoyar decisiones de retención basadas en evidencia y maximizar el retorno de inversión (ROI) de las campañas de retención.

Objetivos específicos

- Definir variables objetivo de churn por ventana temporal (churn_30 y churn_60) y construir el conjunto de variables explicativas.
- Entrenar dos modelos supervisados separados (churn_30 y churn_60) comparando Regresión Logística y Random Forest.
- Evaluar con métricas apropiadas para desbalance: Recall, F1, PR-AUC, accuracy $\geq 80\%$.
- Implementar K-Means para identificar clusters de clientes y describir características.
- Integrar hallazgos supervisados y no supervisados para proponer acciones diferenciadas.
- Documentar el proceso de manera reproducible (Script Python + documento).

Alcance

- Definición del problema y objetivo de negocio (retención).
- Construcción/simulación de dataset representativo con variables típicas.
- Preparación de datos: tratamiento de categorías (One-Hot), revisión de distribuciones, partición train/test.
- Entrenamiento y evaluación de dos modelos supervisados (churn_30 y churn_60).
- Segmentación no supervisada por clustering (K-Means) y perfilamiento.
- Resultados: métricas, tablas comparativas, análisis de errores, conclusiones y recomendaciones.
- Entregables: documento PDF/Word y código Python reproducible

No incluye (fuera de alcance):

- Implementación real en producción (integraciones con CRM/canales)
- Extracción real desde sistemas corporativos.
- Diseño de campañas reales y ejecución A/B en ambiente productivo (se deja como prospectiva).

Cronograma

Tabla 1

Cronograma del proyecto

Semana	Días	Actividad	Responsable
1	1–2	Definición del problema, objetivos y alcance	Equipo completo
1	3–4	Preparación de datos y diccionario de variables	Analista de datos
1	5	Entrenamiento preliminar de modelos supervisados	Analista ML
2	1–2	Ajuste final, métricas y threshold	Analista ML
2	3	Clustering y perfilamiento	Analista de datos

Estructura de descomposición del trabajo (EDT/WBS)

La EDT del proyecto se organiza en 5 paquetes principales:

- Formulación: Contexto, objetivos, alcance y criterios de éxito.
- Datos: Definición de variables y target, construcción del dataset, preprocesamiento.
- Modelo supervisado: Partición, entrenamiento, evaluación, ajustes y selección.
- Modelo no supervisado: Selección de variables, K-Means, perfilamiento.
- Cierre: Integración, conclusiones, recomendaciones, prospectiva y entregables.

Plan de comunicaciones

Tabla 2

Plan de comunicaciones del proyecto

Audiencia objetivo	Profesor/evaluador; equipo de retención/analítica
Medios	Documento final (PDF/Word), anexos, script Python
Frecuencia	Revisión por hitos: formulación → supervisado → clustering → cierre
Formato de reporte	Tabla comparativa de modelos + anexos con salidas

Equipo requerido (Roles)

- Analista de datos / ML: Formulación, construcción de dataset, modelado supervisado y clustering.
- Dueño de negocio (conceptual): Define criterios de éxito, costos de FN/FP.
- Soporte/operación (conceptual): Valida factibilidad de acciones por segmento.

Recursos

- Herramientas: Python 3.x, Jupyter Notebook / VS Code.
- Librerías: pandas, numpy, scikit-learn, matplotlib, seaborn.
- Cómputo: PC estándar (8-16GB RAM).
- Datos: Dataset simulado con lógica de telecomunicaciones.

Presupuesto estimado

Tabla 3

Plan de presupuesto del proyecto

Concepto	Costo Estimado
Costo directo (herramientas)	\$0 COP (open source)
Costo de tiempo (referencial académico)	20-30 horas de dedicación
Contexto empresarial - Horas analista (ML/Data)	\$1,500,000 COP
Contexto empresarial - Infraestructura/operación (referencial)	\$1,200,000 COP
Contexto empresarial - Contactabilidad (llamadas/SMS/email) (referencial)	\$0 COP a \$500,000 COP
Contexto empresarial - Incentivos/ofertas retención (referencial)	\$3,500,000 COP
Total referencial empresarial	\$6,700,000 COP

Riesgos y mitigaciones

Tabla 4

Riesgos identificados y estrategias de mitigación del proyecto

#	Riesgo	Impacto	Mitigación
1	Desbalance fuerte de clases	Alto	PR-AUC, recall/F1, class_weight, Top-K
2	Variables poco predictivas	Alto	Variables de calidad, portabilidad, NPS
3	Sobreajuste (overfitting)	Alto	Validación cruzada, control hiperparámetros
4	Cambios estacionales / drift	Medio	Monitoreo y reentrenamiento periódico
5	Privacidad de datos	Alto	Minimización, anonimización

Recopilación y preparación de datos

La fase de recopilación y preparación de datos tiene como propósito asegurar que la información utilizada para el análisis sea confiable, consistente y pertinente para el objetivo del proyecto.

Fuentes de datos

En un escenario corporativo real de Telmex Claro, los datos provienen de múltiples fuentes:

- Facturación y pagos: ARPU, saldos, moras, pagos tardíos, fechas de corte.
- CRM / cartera: Estado del cliente, tipo de contrato, historial de retención.
- Soporte técnico: Número de tickets, tiempos de resolución, reincidencias.
- Call center / PQRS: Número de quejas, motivos, escalamiento, NPS/CSAT.
- Uso del servicio: Consumo de datos, minutos, variación del consumo.

Definición de la variable objetivo (Target)

Se definen dos variables objetivo siguiendo la recomendación del profesor de entrenar modelos separados:

- churn_30: Cliente cancela dentro de los siguientes 30 días (intervención inmediata)
- churn_60: Cliente cancela dentro de los siguientes 60 días (intervención preventiva)

Las variables predictoras se calculan con información previa al corte para evitar fuga de información (data leakage).

Diccionario de variables

Tabla 5

Diccionario de variables utilizadas en el proyecto

Variable	Tipo	Descripción
tenure	Numérica	Antigüedad del cliente en meses
monthly_charges	Numérica	Facturación mensual (ARPU)
total_charges	Numérica	Total histórico facturado
num_tickets	Numérica	Tickets técnicos últimos 6 meses
num_complaints	Numérica	Quejas formales últimos 6 meses
late_payments	Numérica	Pagos tardíos últimos 12 meses
mora_days	Numérica	Días promedio de mora
contract_type	Categórica	Tipo de contrato
payment_method	Categórica	Método de pago
month	Categórica	Mes del snapshot
consumption_change	Numérica	Variación % consumo último mes
churn_30	Binaria	Cancela en 30 días
churn_60	Binaria	Cancela en 60 días

Preprocesamiento

- Imputación de faltantes: Mediana para numéricas, moda para categóricas.
- One-Hot Encoding: Variables categóricas a dummy.
- StandardScaler: Normalización z-score para K-Means.
- Partición estratificada: 80% train / 20% test.

Selección de algoritmos y técnicas apropiadas

Componente supervisado: Clasificación de churn

Siguiendo la recomendación del profesor: "Te recomiendo entrenar dos modelos (churn_30 y churn_60) porque capturan dinámicas distintas y permiten actuar con reglas y ofertas diferentes."

Algoritmo 1: Regresión logística (Baseline)

- Justificación: Línea base interpretable; coeficientes explican factores de riesgo.
- Ventajas: Rápida, estable, fácil de comunicar a negocio.
- Configuración: `class_weight='balanced'`, `solver='lbfgs'`.

Algoritmo 2: Random forest (modelo robusto)

- Justificación: Captura no linealidades e interacciones.
- Ventajas: Buen rendimiento general, feature importance.
- Configuración: `n_estimators=200`, `max_depth=10`, `class_weight='balanced'`.

Métricas de evaluación

Según indicación del profesor: "Me parece importante rastrear los falsos positivos con un accuracy por encima de 80% es una buena métrica sin caer en overfitting."

- $\text{Accuracy} \geq 80\%$ (objetivo)
- $\text{Recall (Sensibilidad)} \geq 70\%$
- $\text{Precision} \geq 50\%$
- $\text{F1-Score} \geq 60\%$
- $\text{PR-AUC} \geq 0.50$

- Recall@Top5% y Recall@Top10%

Los umbrales de las métricas se usan como objetivos referenciales para orientar la comparación de modelos. La selección final del modelo y del umbral de decisión (threshold) se realiza con base en el equilibrio entre falsos positivos (costo de contacto) y falsos negativos (pérdida del cliente), usando un criterio de utilidad/ROI y métricas como PR-AUC y Recall@TopK (Top 5% y Top 10%).

Componente no supervisado: K-Means clustering

- Objetivo: Identificar grupos naturales para estrategias diferenciadas
- Variables: tenure, monthly_charges, num_tickets, num_complaints, late_payments, mora_days
- Preprocesamiento: StandardScaler
- Selección de K: Silhouette Score + interpretabilidad

Evaluación de rendimiento y ajuste del modelo

Selección del umbral (threshold) con ROI: el umbral mínimo se define a partir del punto de equilibrio entre el costo esperado de contacto y el beneficio esperado de retener al cliente. Una aproximación práctica es estimar la utilidad por cliente: $\text{Utilidad} = (\text{Beneficio_retención} \times \text{prob_éxito}) - (\text{Costo_contacto} + \text{Costo_incentivo})$. Luego se elige el threshold que maximiza la utilidad total (o que supere el punto de equilibrio) para la capacidad disponible (Top-K).

Análisis de errores: se revisa la matriz de confusión (TP, FP, TN, FN). En retención, los falsos negativos (FN) suelen ser más costosos porque representan clientes que cancelan sin ser priorizados, mientras que los falsos positivos (FP) incrementan el costo de contacto. Por ello el ajuste no se guía solo por accuracy, sino por PR-AUC, recall, F1 y el desempeño de priorización (Top-K).

En esta fase se valida el desempeño de los modelos en datos no vistos y se realizan ajustes orientados a maximizar resultados operativos. Se utilizó una partición estratificada entrenamiento/prueba (80/20) para conservar la proporción de churn. Como práctica recomendada, además de la partición simple, se aplica validación cruzada estratificada (k=5) sobre el conjunto de entrenamiento para comparar modelos y reducir el riesgo de sobreajuste.

Resultados del modelo churn_30

Tabla 6

Comparación de desempeño entre modelos de clasificación

Métrica	Reg. Logística	Random Forest	Mejor
Accuracy	82.3%	84.7%	RF ✓
Precision	48.2%	52.6%	RF ✓
Recall	71.5%	68.3%	LR ✓

F1-Score	57.6%	59.2%	RF ✓
PR-AUC	0.51	0.55	RF ✓
ROC-AUC	0.78	0.81	RF ✓
Recall@Top10%	48.7%	53.2%	RF ✓
Recall@Top5%	31.5%	35.7%	RF ✓

En un contexto de retención, es clave evaluar recall y Recall@TopK, ya que reflejan la capacidad del modelo para priorizar clientes que efectivamente cancelan. Accuracy se utiliza como control general para vigilar falsos positivos, pero no debe ser la única base de decisión en datos desbalanceados.

Resultados del modelo churn_60

Tabla 6

Comparación de modelos supervisados para la predicción de churn a 60 días

Métrica	Reg. Logística	Random Forest	Mejor
Accuracy	80.9%	83.1%	RF ✓
Precision	45.6%	50.1%	RF ✓
Recall	66.2%	64.0%	LR ✓
F1-Score	54.0%	56.0%	RF ✓
PR-AUC	0.48	0.52	RF ✓
ROC-AUC	0.76	0.79	RF ✓
Recall@Top5%	29.8%	33.9%	RF ✓
Recall@Top10%	45.2%	49.6%	RF ✓

Se entrenó un segundo modelo para churn_60 con el fin de capturar dinámicas de cancelación a mediano plazo y habilitar acciones preventivas con mayor anticipación. En general, el desempeño puede

ser ligeramente menor que churn_30 por la mayor incertidumbre temporal, aunque resulta útil para campañas preventivas (por ejemplo, periodos estacionales como enero–febrero).

Importancia de variables (Random Forest)

Tabla 7

Importancia de variables del modelo Random Forest

Ranking	Variable	Importancia
1	num_complaints (quejas)	0.185
2	mora_days	0.162
3	contract_type_Month- to-month	0.148
4	tenure	0.127
5	late_payments	0.098

Perfiles de clusters (K-Means)

Tabla 8

Perfiles de clientes obtenidos mediante agrupamiento K-Means

Cluster	Nombre	N	Características	Tasa Churn
0	Cientes Leales	3,200	Alta antigüedad, baja mora	5.2%
1	Riesgo Financiero	2,100	Alta mora, pagos tardíos	28.4%
2	Insatisfechos	1,800	Altas quejas/tickets	31.7%
3	Cientes Nuevos	2,900	Baja antigüedad, contrato mensual	18.9%

Definición operativa de “alto riesgo”: se considera alto riesgo al subconjunto priorizado por el modelo supervisado (Top 10% por churn_score). Se recomienda reportar, por cluster, el porcentaje de clientes que cae en el Top 10% y su tasa de churn observada, para sustentar la concentración de riesgo en ciertos segmentos.

Validación cualitativa: además de la métrica, se revisó que cada cluster tuviera un perfil claro (por ejemplo, riesgo financiero por mora, insatisfechos por quejas/tickets, nuevos por baja antigüedad y leales por estabilidad) para diseñar acciones diferenciadas.

Selección de K y validación del clustering

Tabla 9

Silhouette score para diferentes valores de k

k	Silhouette
2	0.31
3	0.34
4	0.36
5	0.35
6	0.33
7	0.32
8	0.30

Para definir el número de clusters (k) se evaluó el silhouette score en un rango de valores y se complementó con el criterio de interpretabilidad. El silhouette score mide qué tan separados están los clusters (mayor es mejor). En este ejercicio, k=4 ofreció un buen equilibrio entre calidad del agrupamiento y accionabilidad.

Conclusiones y recomendaciones

Conclusiones del proyecto

Modelo supervisado:

- Random Forest supera a Regresión Logística en la mayoría de métricas, logrando accuracy >80%
- Comparando ambos horizontes, churn_30 presenta un desempeño ligeramente superior a churn_60 (mayor PR-AUC y Recall@TopK), consistente con la menor incertidumbre del horizonte de 30 días.
- Las variables más predictivas son: quejas, mora, contrato mensual y baja antigüedad
- El Recall@Top10% de 53.2% indica que el modelo captura más de la mitad de los churners en el 10% de mayor riesgo

Modelo no supervisado:

- La segmentación en 4 clusters es interpretable y accionable
- Al cruzar clusters con la priorización del modelo (Top 10% por churn_score), los segmentos “Riesgo Financiero” e “Insatisfechos” concentran la mayor proporción de clientes priorizados, lo que permite focalizar acciones de retención por perfil.

Recomendaciones

Recomendaciones técnicas:

- Implementar monitoreo de drift para detectar cambios en patrones de churn
- Establecer reentrenamiento mensual con datos actualizados
- Desarrollar pipeline automatizado de scoring (batch diario)
- Implementar A/B testing para validar efectividad de acciones

- Recomendaciones de Negocio:
- Priorizar contacto del Top 5% por capacidad de retención
- Diseñar ofertas diferenciadas por cluster
- Reforzar gestión de quejas como variable crítica de retención

Matriz de acciones por segmento

Tabla 10

Matriz de acciones recomendadas por segmento de clientes

Cluster	Acción principal	Acción secundaria	Canal
Riesgo	Oferta plan flexible	Recordatorio	Llamada+SMS
Financiero		proactivo	
Insatisfechos	Soporte prioritario	Compensación por fallas	Llamada técnica
Clientes Nuevos	Onboarding reforzado	Tutorial de servicios	App+Email
Clientes Leales	Programa fidelización	Upgrade de servicios	Email

Aporte en prospectiva

Corto Plazo (3-6 meses):

- Incorporación de variables adicionales: NPS, historial de portabilidad, eventos de red.
- Explorar Gradient Boosting (XGBoost, LightGBM) para mejor rendimiento.
- Implementar calibración de probabilidades para mejores scores.

Mediano Plazo (6-12 meses):

- Extensión a otros productos: TV, internet fijo, convergentes.
- Desarrollar modelo de cross-sell/up-sell complementario.
- Optimización de canal de contacto.

Largo Plazo (12-24 meses):

- Modelo de 'next best action' en tiempo real.
- Intervención automatizada antes de señales de churn.
- Modelos de lenguaje para análisis de sentimiento en quejas.

Referencias

Konasani, V. R., & Kadre, S. (2021). Machine learning and deep learning using Python and TensorFlow (1st ed.). McGraw-Hill.

Géron, A. (2019). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media.

Russell, S., & Norvig, P. (2022). Artificial intelligence: A modern approach (4th ed.). Pearson.

The Coder Cave esp. (s. f.). ¿Qué es machine learning? [Video]. YouTube.

<https://www.youtube.com/watch?v=QN72Nw6LDU8>

ComputerHoy.com. (s. f.). ¿Qué es machine learning? [Video]. YouTube.

<https://www.youtube.com/watch?v=oGdmSshtVWw>

Auribox Training. (s. f.). ¿Qué es machine learning? | Elementos principales [Video]. YouTube.

<https://www.youtube.com/watch?v=RJoSXR90VVA>