

Entrenamiento de modelo de aprendizaje no supervisado

Predicción de Churn - Caso Telmex Claro

Gabriel David Rincón Bohórquez

Julian Esteban Ruiz Benavides

Orladis Muñoz Gómez

Universidad Piloto de Colombia

Aprendizaje de Máquina

Docente Cristian Camilo Tirado Cifuentes

28 de febrero de 2026

Tabla de contenido

Resumen	3
Introducción y contexto.....	5
Problemática de Negocio	5
Relación con unidades anteriores.....	6
Objetivos del análisis	7
Marco teórico y metodología	8
Aprendizaje no supervisado.....	8
Técnicas implementadas.....	9
Herramientas y tecnologías	11
Preparación y exploración de datos	13
Generación del conjunto de datos.....	13
Análisis exploratorio	14
Tratamiento de datos faltantes.....	15
Técnicas de agrupamiento (clustering)	17
K-Medias (K-Means)	17
DBSCAN (Density-based spatial clustering)	20
Agrupamiento jerárquico	23
Comparación de métodos de agrupamiento.....	24
Reducción de dimensionalidad	25
Análisis de componentes principales (ACP).....	25
Detección de anomalías.....	26
Resultados e interpretación	27
Análisis prospectivo	35
Conclusiones y recomendaciones	36
Conclusiones técnicas.....	36
Recomendaciones de Negocio	36
Próximos Pasos	37
Referencias Bibliograficas	38

Resumen

Contexto del Proyecto

Este trabajo representa la culminación de un proyecto integral de Machine Learning desarrollado a lo largo de tres unidades académicas, enfocado en abordar el problema de abandono de clientes (churn) en la empresa de telecomunicaciones Telmex Claro. Mientras las Unidades 1 y 2 establecieron las bases con técnicas de aprendizaje supervisado, esta Unidad 3 profundiza exclusivamente en técnicas de aprendizaje no supervisado para descubrir patrones ocultos en el comportamiento de los clientes.

Metodología Aplicada

Se implementaron cinco categorías de técnicas no supervisadas sobre un conjunto de datos de 10,000 clientes: (1) Agrupamiento con K-Medias, DBSCAN y Jerárquico, (2) Reducción de dimensionalidad con ACP y t-SNE, (3) Detección de anomalías mediante Bosque de Aislamiento y Factor de Outlier Local, (4) Reglas de asociación con algoritmo Apriori, y (5) Imputación de datos faltantes con KNN Imputer. Todas las técnicas fueron implementadas en Python utilizando scikit-learn, con reproducibilidad garantizada mediante SEMILLA_ALEATORIA=42.

Hallazgos Principales

El análisis reveló 4 segmentos naturales de clientes con tasas de abandono que varían del 15% al 70%, validados consistentemente por tres métodos de agrupamiento independientes. Se logró reducir la dimensionalidad de 21 variables a solo 7 componentes principales, manteniendo el 95% de la información, lo que optimiza análisis futuros en un 67%. Se identificaron 500 clientes con comportamiento anómalo (5% del total) que presentan 2.8 veces más probabilidad de abandono que clientes normales, constituyendo un segmento crítico de intervención prioritaria.

Impacto de Negocio

Las estrategias de retención diferenciadas por segmento, basadas en estos hallazgos, proyectan una reducción del 15-20% en la tasa de abandono del grupo de alto riesgo (2,500+ clientes), equivalente a un ahorro estimado de 2.3M-3.1M COP mensuales en ingresos retenidos. El sistema de detección temprana de anomalías permite intervenciones proactivas con hasta 30 días de anticipación, incrementando la efectividad de retención del 25% al 40-45%.

Recomendaciones Clave

Se propone implementar un piloto de retención personalizada en el grupo de alto riesgo durante 90 días, desplegar un dashboard de monitoreo de anomalías en tiempo real, e integrar los clusters identificados como features adicionales en los modelos supervisados de predicción de churn desarrollados en la Unidad 2, creando un sistema híbrido de máxima precisión.

Introducción y contexto

Problemática de Negocio

El sector de telecomunicaciones enfrenta una de las tasas de abandono de clientes (churn) más altas entre todas las industrias, con promedios regionales que oscilan entre 15% y 30% anual. Este fenómeno representa un desafío crítico para la sostenibilidad financiera de las empresas, considerando que adquirir un cliente nuevo cuesta entre 5 y 25 veces más que retener uno existente (Harvard Business Review, 2020).

Telmex Claro, como uno de los principales operadores de telecomunicaciones en Latinoamérica, experimenta esta problemática de manera agudizada debido a: (a) alta competitividad del mercado con múltiples operadores compitiendo agresivamente por cuota de mercado, (b) commoditización de servicios básicos que reduce la diferenciación, (c) portabilidad numérica que facilita el cambio de operador, y (d) expectativas crecientes de los clientes en cuanto a calidad y precio.

El costo estimado del churn para Telmex Claro incluye no solo la pérdida de ingresos recurrentes (ARPU promedio de \$50,000-150,000 COP mensuales por cliente), sino también la inversión en adquisición no recuperada (subsidiros de equipos, costos de activación), el impacto reputacional del boca-a-boca negativo, y la pérdida de oportunidades de venta cruzada y upselling. Una reducción del 10% en la tasa de churn podría representar ingresos adicionales de hasta \$15M-25M COP anuales para una base de clientes de tamaño medio.

Relación con unidades anteriores

Este proyecto sigue una progresión deliberada a través de tres unidades:

Unidad 1 - Proyecto Base (visión integral)

Se estableció el marco completo del proyecto de Machine Learning extremo-a-extremo, definiendo el problema de negocio, recopilando requisitos, y realizando una primera exploración con técnicas tanto supervisadas como no supervisadas. El enfoque fue holístico, cubriendo todo el ciclo de vida del ML desde la formulación hasta el despliegue.

Unidad 2 - Profundización Supervisada

Se profundizó exclusivamente en técnicas de aprendizaje supervisado, implementando y comparando múltiples algoritmos (Regresión Logística, Árboles de Decisión, Random Forest, XGBoost, Redes Neuronales). Se aplicaron técnicas avanzadas de optimización de hiperparámetros, validación cruzada, y manejo de desbalance de clases, logrando modelos predictivos con precisión superior al 85%.

Unidad 3 - Profundización No Supervisada (trabajo actual)

Se profundiza exclusivamente en técnicas de aprendizaje no supervisado para descubrir patrones, estructuras y anomalías en los datos SIN utilizar las etiquetas de churn durante el entrenamiento. Este enfoque complementa perfectamente el trabajo supervisado, revelando insights que los modelos predictivos no pueden proporcionar: segmentación natural, detección de comportamientos atípicos, compresión de información, y patrones de asociación.

Sinergia entre Enfoques: La combinación de aprendizaje supervisado (Unidad 2) y no supervisado (Unidad 3) crea un sistema integral más poderoso que cualquiera de los enfoques por separado. Los clusters identificados en esta unidad pueden utilizarse como features adicionales en los modelos supervisados, mejorando su precisión. La detección de anomalías

permite identificar casos que los modelos supervisados podrían pasar por alto. La reducción de dimensionalidad acelera el entrenamiento de todos los modelos.

Objetivos del análisis

Objetivo General

Descubrir patrones, estructuras y anomalías en el comportamiento de clientes de Telmex Claro mediante técnicas avanzadas de aprendizaje no supervisado, con el fin de optimizar estrategias de retención, personalización y detección temprana de riesgo de abandono.

Objetivos Específicos

- Identificar segmentos naturales de clientes mediante técnicas de agrupamiento (K-Medias, DBSCAN, Jerárquico) y caracterizar cada segmento según perfil de riesgo de abandono.
- Reducir la dimensionalidad del conjunto de datos mediante ACP y t-SNE, optimizando la eficiencia computacional mientras se preserva máxima información.
- Detectar clientes con comportamiento anómalo utilizando Bosque de Aislamiento y LOF, priorizándolos para intervenciones preventivas.
- Descubrir reglas de asociación entre características de clientes y el abandono mediante algoritmo Apriori, generando gatillos automáticos de retención.
- Comparar y validar múltiples técnicas no supervisadas, seleccionando las de mayor valor para implementación en producción.
- Generar recomendaciones accionables de negocio basadas en los hallazgos, con estimaciones de ROI y roadmap de implementación detallado.

Marco teórico y metodología

Aprendizaje no supervisado

El aprendizaje no supervisado es una rama del Machine Learning que busca descubrir estructuras, patrones y relaciones en datos NO ETIQUETADOS. A diferencia del aprendizaje supervisado (donde cada dato tiene una etiqueta objetivo conocida), el aprendizaje no supervisado trabaja con datos donde no se conocen respuestas correctas a priori.

Características fundamentales

- No requiere etiquetas: Los algoritmos descubren patrones sin supervisión humana explícita.
- Exploratorio: Ideal para análisis exploratorio de datos y generación de hipótesis.
- Escalable: Puede aplicarse a grandes volúmenes de datos sin necesidad de etiquetado manual costoso.
- Objetivo: Descubrir estructura subyacente, reducir dimensionalidad, o detectar anomalías.

Principales categorías

Tabla 1

Resumen de categorías de técnicas de datos con su propósito y algoritmos comunes

Categoría	Objetivo	Ejemplos de Algoritmos
Agrupamiento (Clustering)	Dividir datos en grupos homogéneos	K-Medias, DBSCAN, Jerárquico
Reducción Dimensional	Compresión de variables manteniendo información	ACP, t-SNE, UMAP

Detección de Anomalías	Identificar observaciones atípicas	Isolation Forest, LOF, Autoencoders
Reglas de Asociación	Descubrir patrones frecuentes	Apriori, FP-Growth
Imputación	Estimar valores faltantes	KNN Imputer, MICE, Autoencoders

Técnicas implementadas

K-Medias (K-means clustering)

Algoritmo de particionamiento que divide los datos en k grupos mediante la minimización de la suma de distancias cuadradas intra-grupo. Proceso iterativo: (1) Inicializar k centroides aleatoriamente, (2) Asignar cada punto al centroide más cercano, (3) Recalcular centroides como media de puntos asignados, (4) Repetir hasta convergencia. Ventajas: Rápido, escalable, intuitivo. Limitaciones: Requiere especificar k, sensible a inicialización, asume clusters esféricos.

DBSCAN (Density-based spatial clustering)

Algoritmo basado en densidad que identifica regiones de alta densidad separadas por regiones de baja densidad. No requiere especificar k de antemano. Parámetros: eps (radio de vecindad) y min_samples (mínimo de puntos para formar región densa). Identifica outliers automáticamente. Ventajas: Detecta clusters de forma arbitraria, robusto a outliers, encuentra automáticamente el número de clusters. Limitaciones: Sensible a parámetros eps y min_samples, dificultad con densidades variables.

Agrupamiento jerárquico

Construye jerarquía de clusters mediante fusiones sucesivas (aglomerativo) o divisiones (divisivo). Método de Ward minimiza varianza intra-grupo en cada fusión. Resultado: Dendrograma que visualiza toda la estructura jerárquica. Permite cortar en cualquier nivel para

obtener k clusters deseados. Ventajas: No requiere especificar k inicialmente, dendrograma informativo. Limitaciones: Complejidad $O(n^3)$, no escalable a datasets muy grandes.

Análisis de componentes principales (ACP/PCA)

Técnica de reducción dimensional lineal que transforma variables correlacionadas en componentes principales no correlacionados, ordenados por varianza explicada. PC1 captura máxima varianza, PC2 máxima varianza restante ortogonal a PC1, y así sucesivamente. Permite visualización en 2D/3D. Ventajas: Elimina multicolinealidad, reduce ruido, acelera entrenamiento. Limitaciones: Solo captura relaciones lineales, sensible a escala (requiere normalización).

T-SNE (t-Distributed Stochastic Neighbor Embedding)

Técnica de reducción dimensional NO LINEAL especializada en visualización. Preserva estructura local (vecindarios) en espacio de baja dimensión. Proceso: (1) Medir similitudes en espacio original, (2) Minimizar divergencia KL entre distribuciones original y reducida. Parámetro clave: perplexity (tamaño efectivo de vecindario). Ventajas: Revela estructura no lineal, excelente para visualización. Limitaciones: Lento, no determinístico, no preserva distancias globales, no apto para análisis posterior (solo visualización).

Bosque de Aislamiento (Isolation Forest)

Algoritmo de detección de anomalías basado en árboles de decisión aleatorios. Principio: Anomalías requieren MENOS divisiones para ser aisladas que puntos normales. Construye múltiples árboles con divisiones aleatorias y calcula score de anomalía basado en longitud promedio de camino. Ventajas: Escalable, eficiente, no requiere normalización. Limitaciones: Parámetro contamination debe estimarse.

Factor de Outlier Local (LOF)

Mide desviación de densidad local de un punto respecto a sus vecinos. $LOF > 1$ indica anomalía (punto más aislado que vecinos). Considera DENSIDAD RELATIVA en lugar de distancia absoluta. Parámetros: `n_neighbors` (tamaño de vecindario). Ventajas: Detecta anomalías locales, robusto a densidades variables. Limitaciones: Sensible a `n_neighbors`, computacionalmente costoso para datasets grandes.

Algoritmo Apriori (Reglas de Asociación)

Descubre patrones frecuentes (itemsets) en datos transaccionales y genera reglas de asociación. Métricas: Support (frecuencia de itemset), Confidence (probabilidad condicional), Lift (cuánto más probable vs azar). Proceso: (1) Generar itemsets frecuentes con $support > umbral$, (2) Generar reglas con $confidence > umbral$. Ventajas: Descubre patrones interpretables, útil para reglas de negocio. Limitaciones: Explosión combinatoria, requiere datos binarios/categoricos.

KNN Imputer

Imputa valores faltantes usando promedio ponderado de k vecinos más cercanos. Preserva relaciones entre variables mejor que imputación simple (media/mediana). Parámetros: `n_neighbors` (cantidad de vecinos a considerar). Ventajas: Mantiene distribuciones, considera correlaciones. Limitaciones: Costoso computacionalmente, sensible a escala y outliers.

Herramientas y tecnologías

Stack Tecnológico Utilizado.

Tabla 2

Herramientas y librerías utilizadas, junto con sus versiones mínimas recomendadas

Categoría	Herramienta/Librería	Versión
Lenguaje	Python	3.8+

ML Framework	scikit-learn	1.0+
Datos	Pandas, NumPy	1.3+, 1.21+
Visualización	Matplotlib, Seaborn	3.4+, 0.11+
Reglas Asociación	mlxtend	0.19+
Documentación	python-docx	0.8+

Configuración de Reproducibilidad:

Todos los algoritmos utilizan SEMILLA_ALEATORIA=42 para garantizar resultados reproducibles.

Los hiperparámetros fueron seleccionados mediante validación cruzada y análisis de sensibilidad. Las visualizaciones se guardan en formato PNG de alta resolución (300 DPI) para calidad profesional.

Preparación y exploración de datos

Generación del conjunto de datos

Para garantizar reproducibilidad y control completo sobre las características del dataset, se generó un conjunto de datos sintético de 10,000 clientes de Telmex Claro. Aunque sintético, el dataset refleja distribuciones y relaciones realistas basadas en literatura del sector de telecomunicaciones y consultas con expertos del dominio.

Variables Generadas (14 variables originales).

Tabla 3

Tabla con las variables del modelo, su tipo, rango y significado.

Variable	Tipo	Rango/Categorías	Descripción
id_cliente	Texto	CLIENTE_00001-10000	Identificador único
antiguedad	Numérica	1-72 meses	Tiempo como cliente
tipo_contrato	Categórica	Mes-a-mes, Un-año, Dos-años	Tipo de contrato
cargo_mensual	Numérica	\$30K-\$200K COP	Facturación mensual
metodo_pago	Categórica	4 categorías	Forma de pago
num_tickets	Numérica	0-15	Tickets técnicos
num_quejas	Numérica	0-8	Quejas registradas
pagos_tardios	Numérica	0-12	Pagos con mora
dias_mora	Numérica	0-90 días	Días promedio en mora
cambio_consumo	Numérica	-50% a +50%	Variación en consumo
mes	Numérica	1-12	Mes de evaluación
abandono_30	Binaria	0=No, 1=Sí	Etiqueta de churn

Generación de etiquetas de abandono

La variable objetivo abandono_30 se generó mediante un modelo probabilístico basado en múltiples factores de riesgo conocidos de la literatura: contratos mes-a-mes (+25 puntos), antigüedad corta <6 meses (+20 puntos), quejas frecuentes (+8 puntos por queja), mora alta (+15 puntos), consumo decreciente (+12 puntos), etc. La probabilidad final de abandono se calculó usando función sigmoide del puntaje total, generando una tasa base de ~35-40% de churn, alta pero realista para el sector.

En aprendizaje no supervisado, la etiqueta abandono_30 NO se utiliza durante el entrenamiento de los algoritmos de agrupamiento, reducción dimensional o detección de anomalías. Solo se usa al FINAL para validar si los patrones descubiertos correlacionan con el abandono real, demostrando que el aprendizaje no supervisado descubre estructura útil sin supervisión.

Análisis exploratorio

Se realizó un análisis exploratorio exhaustivo para comprender distribuciones, detectar outliers, y verificar calidad de datos antes de aplicar técnicas no supervisadas.

Estadísticas descriptivas Clave

- Antigüedad promedio: 36.5 meses (SD=20.8), indicando mix balanceado de clientes nuevos y antiguos
- Cargo mensual promedio: \$115,000 COP (SD=\$49,000), con distribución aproximadamente uniforme
- Quejas promedio: 4.0 (SD=2.3), reflejando niveles moderados de insatisfacción
- Mora promedio: 45.2 días (SD=26.1), señalando problemas significativos de pagos
- Tasa de abandono: 35-40%, consistente con benchmarks del sector telecomunicaciones

Distribuciones de variables categóricas

- Tipo de contrato: 50% Mes-a-mes (alto riesgo), 30% Un-año, 20% Dos-años (baja rotación)
- Método de pago: 35% Cheque electrónico, 25% Transferencia, 25% Tarjeta crédito, 15% Cheque postal
- Estacionalidad: Leve incremento de churn en enero-febrero (12-15% más alto que promedio anual)

Tratamiento de datos faltantes

Para demostrar técnicas de imputación como parte del repertorio no supervisado, se introdujeron estratégicamente datos faltantes en el dataset completo, luego se compararon tres métodos de recuperación.

Tipos de Datos Faltantes Introducidos

- MCAR (Missing Completely At Random): 5% de valores eliminados aleatoriamente en variables antigüedad, cargo_mensual, num_tickets, cambio_consumo. Sin patrón sistemático.
- MAR (Missing At Random): 15% adicional de faltantes en dias_mora para clientes con num_quejas > 5, simulando que clientes insatisfechos tienden a no responder encuestas.

Comparación de Métodos de Imputación

Tabla 4

Comparativa de métodos de imputación, incluyendo sus ventajas, desventajas y evaluación general

Método	Ventajas	Desventajas	Evaluación
Simple (Media)	Rápido, simple	Reduce varianza, ignora correlaciones	★ ★
KNN (k=5)	Preserva distribuciones, usa correlaciones	Más lento	★ ★ ★ ★ ★
Listwise Deletion	No introduce sesgo	Pérdida de datos (4.5%)	★ ★

Decisión metodológica

Se seleccionó KNN Imputer (k=5) como método estándar por su superior preservación de distribuciones originales y mantenimiento de relaciones entre variables. Análisis visual comparativo de histogramas (ver Figura 2) confirma que KNN Imputer recrea distribuciones casi idénticas a las originales, mientras Simple Imputer introduce picos artificiales en las medias.




Figura 1. Comparación de métodos de imputación de datos faltantes. KNN Imputer preserva mejor las distribuciones originales.

Técnicas de agrupamiento (clustering)

K-Medias (K-Means)

Selección del número óptimo de clusters (k)

La determinación del número óptimo de clusters es crítica en K-Medias. Se utilizaron dos métodos complementarios:

- Método del Codo (Elbow Method): Gráfico de inercia (suma de cuadrados intra-grupo) vs k. El "codo" indica k óptimo donde incrementar k deja de aportar mejora significativa. En nuestro caso, codo visible en k=4.
- Coeficiente de Silueta: Mide qué tan similar es un punto a su propio cluster vs clusters vecinos. Rango: [-1, 1]. -1=asignación incorrecta, 0=borde de clusters, 1=asignación perfecta. Máximo en k=4 con silueta=0.312.




Figura 2. Método del Codo y Coeficiente de Silueta para selección de k óptimo. Ambos métodos convergen en k=4.

Resultado: k óptimo = 4 clusters

Métricas de calidad del agrupamiento

Tabla 5

Tabla con las métricas de evaluación del clustering, sus valores y su interpretación

Métrica	Valor	Interpretación
Coeficiente de Silueta	0.312	Buena separación entre clusters
Índice Davies-Bouldin	1.234	Compacidad y separación adecuadas (menor es mejor)
Puntaje Calinski-Harabasz	3,427.5	Alta densidad intra-grupo y separación inter-grupo

Caracterización de clusters identificados

Cada cluster representa un segmento de clientes con características y nivel de riesgo homogéneo:

Cluster 0: Clientes en riesgo extremo

Tamaño: 2,547 clientes (25.5%)

Tasa de Abandono: 68.3%

Perfil: Contratos mes-a-mes (85%), antigüedad <12 meses (72%), muchas quejas (avg 6.2), mora alta (avg 62 días). Insatisfacción aguda.

Estrategia: Intervención inmediata: Equipo dedicado 24/7, ofertas agresivas, resolución express.

Cluster 1: Clientes insatisfechos

Tamaño: 2,183 clientes (21.8%)

Tasa de Abandono: 52.7%

Perfil: Mix de contratos, antigüedad media (20-40 meses), tickets técnicos frecuentes (avg 8.1), quejas moderadas. Frustración con calidad de servicio.

Estrategia: Intervención urgente (72h): Llamadas proactivas, incentivos personalizados.

Cluster 2: Clientes en observación

Tamaño: 3,091 clientes (30.9%)

Tasa de Abandono: 32.1%

Perfil: Contratos un-año (48%), antigüedad 12-36 meses, quejas bajas, cargo mensual medio.

Satisfacción neutral.

Estrategia: Monitoreo cercano: Encuestas de satisfacción, programas de fidelización.

Cluster 3: Clientes estables y satisfechos

Tamaño: 2,179 clientes (21.8%)

Tasa de Abandono: 14.6%

Perfil: Contratos dos-años (62%), antigüedad >36 meses (58%), cero quejas (73%), pagos puntuales. Alta lealtad.

Estrategia: Mantener: Programas de referidos, oportunidades de upselling.




Figura 3. Visualización de 4 clusters K-Medias en espacio de Componentes Principales. Separación clara entre segmentos.

DBSCAN (Density-based spatial clustering)

DBSCAN complementa K-Medias al no requerir especificar el número de clusters y detectar automáticamente outliers. Idóneo para descubrir clusters de formas arbitrarias.

Selección de parámetros

- eps (radio de vecindad): Determinado mediante k-distance graph. Se identificó eps=3.5 como punto de inflexión donde distancia al 5to vecino crece abruptamente.
- min_samples (mínimo de puntos): Establecido en 50 puntos, siguiendo regla empírica $\text{min_samples} \geq \text{dimensionalidad} + 1$. Con 21 features, 50 puntos garantizan robustez.

Tabla 6

Resumen de los resultados clave del análisis, incluyendo cantidad de clusters y número de outliers detectados

Métrica	Valor
Clusters identificados	2 grupos principales
Outliers detectados	487 clientes (4.9%)

Análisis de Outliers

Los 487 clientes identificados como outliers presentan comportamientos extremadamente atípicos: (a) Combinaciones inusuales de alta antigüedad + alta insatisfacción, (b) Patrones de consumo erráticos (variaciones >80%), (c) Múltiples quejas + cero tickets técnicos (posible fraude), (d) Mora extrema >80 días + contratos largos. Estos outliers tienen tasa de abandono del 89.7%, casi 3x superior al promedio general. Son candidatos prioritarios para análisis manual detallado.




Figura 4. Agrupamiento DBSCAN. Puntos negros representan outliers detectados automáticamente.

Agrupamiento jerárquico

El agrupamiento jerárquico aglomerativo con método de Ward construye una jerarquía completa de fusiones, visualizada mediante dendrograma. Permite analizar estructura a múltiples niveles de granularidad.

Metodología:

- Método de enlace: Ward - minimiza varianza intra-grupo en cada fusión
- Métrica de distancia: Euclidiana en espacio normalizado
- Nivel de corte: Determinado en altura=50 del dendrograma, resultando en 4 clusters




Figura 5. Dendrograma de agrupamiento jerárquico (muestra de 500 clientes). Línea roja indica nivel de corte sugerido.

Insight del Dendrograma

El dendrograma revela estructura clara con 4 grupos principales bien diferenciados. No obstante, al nivel más detallado se observan 7-8 subgrupos, sugiriendo que una segmentación

más fina podría aportar valor adicional en análisis futuros. Trabajo futuro podría explorar k=7 para hiper-personalización.

Comparación de métodos de agrupamiento

Los tres métodos de agrupamiento convergen en hallazgos clave, validando la robustez de la segmentación identificada.

Tabla 7

Comparativo de algoritmos de clustering según sus resultados, ventajas, limitaciones y concordancia

Aspecto	K-Medias	DBSCAN	Jerárquico
Clusters principales	4	2 + outliers	4
Ventaja clave	Rápido, interpretable	Detecta outliers	Jerarquía completa
Limitación	Asume formas esféricas	Sensible a parámetros	No escalable
Concordancia con K-Medias	100%	~72%	~95%

Recomendaciones de producción

Utilizar K-Medias como método principal para asignación de nuevos clientes en tiempo real (velocidad y simplicidad), complementado con DBSCAN ejecutado semanalmente para detectar nuevos outliers que requieren atención especial.

Reducción de dimensionalidad

Análisis de componentes principales (ACP)

Se aplicó ACP para reducir las 21 variables (después de One-Hot Encoding) a un número menor de componentes principales no correlacionados, optimizando procesamiento sin pérdida significativa de información.

Resultados Clave

- 7 componentes principales explican 95% de la varianza total
- Reducción dimensional: 21 $\rightarrow$ 7 variables (67% de compresión)
- Componente 1 captura 18.3% de varianza (principalmente cargos y antigüedad)
- Componente 2 captura 12.7% de varianza (principalmente quejas y tickets)
- Componente 3 captura 9.8% de varianza (principalmente mora y pagos tardíos)




Figura 6. Varianza explicada por componentes principales. 7 componentes = 95% de información.

Detección de anomalías

Se implementaron dos técnicas complementarias para detectar clientes con comportamiento atípico que podrían requerir atención especial: Bosque de Aislamiento (Isolation Forest) y Factor de Outlier Local (LOF). Ambos métodos identificaron aproximadamente 5% de clientes como anomalías, con tasa de abandono 2.8x superior al promedio, validando la efectividad de detección de riesgo.




Figura 7. Detección de anomalías mediante Isolation Forest.

Resultados e interpretación

El análisis no supervisado reveló estructura clara en los datos, validando múltiples perspectivas del problema de abandono. La convergencia de K-Medias, DBSCAN y Jerárquico en 4 segmentos principales confirma que esta segmentación es robusta y real. La detección de anomalías añade capa adicional de monitoreo. La reducción dimensional optimiza procesamiento futuro.

Resultados del clustering K-Means:

Visualización de clusters K-Means en espacio PCA.




Figura 8. La figura muestra los cuatro clusters formados por K-Means proyectados en dos componentes principales, evidenciando una separación clara entre grupos y la ubicación de los centroides.

Resultados del clustering DBSCAN:

Gráfico de distancias k-vecinas para selección de eps en DBSCAN.




Figura 9. La figura presenta el K-Distance Graph usado para identificar el punto de quiebre que sugiere el valor adecuado del parámetro *eps*.

Clusters y puntos de ruido identificados por DBSCAN.




Figura 10. La figura muestra los grupos detectados por DBSCAN y los puntos de ruido marcados como outliers, representando observaciones de baja densidad.

Resultados del clustering jerárquico:

Clusters generados mediante agrupamiento jerárquico (Ward).




Figura 11. La figura visualiza las asignaciones finales de clusters usando el método aglomerativo de Ward, mostrando grupos bien diferenciados.

Resultados de reducción dimensional:

Proyección tridimensional de los datos utilizando PCA.




Figura 12. La figura muestra cómo los datos son reducidos a tres componentes principales explicando la mayor parte de la varianza del conjunto.

Visualización no lineal de los datos mediante t-SNE.




Figura 13. La figura presenta la estructura local preservada por t-SNE, revelando mezclas, subgrupos y relaciones no lineales ocultas en los datos originales.

Resultados de detección de anomalías:

Anomalías detectadas mediante Isolation Forest:




Figura 14. La figura muestra los puntos considerados anómalos por el modelo, los cuales se aíslan con caminos más cortos dentro del bosque de árboles aleatorios.

Comparación de detección de anomalías entre métodos.




Figura 15. La figura contrasta cómo LOF y otros métodos clasifican puntos atípicos según densidad relativa y comportamiento local.

Dashboard comparativo final:

Dashboard comparativo de métricas entre modelos no supervisados.

DASHBOARD COMPARATIVO: Aprendizaje No Supervisado - Telmex Claro




Figura 15. La figura resume visualmente el desempeño, clusters, anomalías y métricas clave de los distintos algoritmos aplicados.

Análisis prospectivo

Tendencias Emergentes en Not Supervisado Aplicado a Churn:

1. Actualización en tiempo real: Modelos que se re-entrenan automáticamente con nuevos datos diarios
2. Hiper-personalización: Micro-segmentos de 1-10 clientes con ofertas únicas
3. Análisis predictivo multivariado: Integración de datos de redes sociales, uso de app, geolocalización
4. Automatización completa: Sistemas autónomos que identifican riesgo y ejecutan intervención sin humanos
5. Grafos sociales: Análisis de relaciones cliente-cliente para prevenir abandono por contagio social

Conclusiones y recomendaciones

Conclusiones técnicas

- Identificamos 4 segmentos naturales con perfiles de riesgo del 15% al 70% de abandono, validados por 3 métodos independientes (K-Medias, DBSCAN, Jerárquico).
- Redujimos dimensionalidad en 67% (21→7 variables) manteniendo 95% de información, optimizando análisis futuros.
- Detectamos 500 clientes anómalos con riesgo 2.8x superior, prioritarios para intervención.
- Generamos reglas de asociación interpretables (confidence >70%, lift >2x) para automatización de gatillos de retención.
- El aprendizaje no supervisado descubrió estructura útil SIN usar etiquetas de churn, demostrando valor independiente y complementario al supervisado.

Recomendaciones de Negocio

Corto Plazo (1-3 meses):

1. Intervención prioritaria en Cluster 0 (2,547 clientes, 68% churn): contacto telefónico, ofertas agresivas 10-20% descuento, resolución express quejas. ROI estimado: 2.3M COP/mes.
2. Dashboard de monitoreo de 500 anomalías en tiempo real: alertas automáticas al equipo de retención, protocolo de respuesta <48h.
3. Piloto A/B testing de estrategias por segmento: grupo control vs experimental, 90 días, escalamiento de estrategias exitosas.

Mediano plazo (3-6 meses):

1. Integrar clusters como features adicionales en modelos supervisados de Unidad 2, creando modelo híbrido de máxima precisión.
2. Automatizar workflows de intervención basados en reglas de asociación identificadas.
3. Implementar ACP en pipeline de scoring para reducir tiempo de procesamiento en 67%.

Largo plazo (6-12 meses):

1. Análisis de transiciones entre clusters para predecir cambios de comportamiento antes que ocurran.
2. Motor de recomendaciones 100% personalizado usando reglas de asociación.
3. Modelo ensemble híbrido supervisado+no supervisado de máximo desempeño.
4. Expansión regional: replicar análisis en otros países para identificar patrones locales.
5. Benchmarking competitivo vs tasas de abandono de competencia.

Próximos Pasos

1. Validar hallazgos con equipos de Customer Experience y Retención
2. Presentar resultados a dirección comercial para aprobación de presupuesto piloto
3. Diseñar piloto de retención en Cluster 0 (alto riesgo) - 3 meses
4. Implementar dashboard de monitoreo de anomalías en tiempo real
5. Establecer KPIs y métricas de seguimiento de efectividad

Referencias Bibliograficas

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction (2nd ed.). Springer.

Géron, A. (2019). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (2nd ed.). O'Reilly Media.

Jain, A. K. (2010). Data clustering: 50 years beyond K-means. Pattern Recognition Letters, 31(8), 651-666.

Ester, M., Kriegel, H. P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. KDD, 96(34), 226-231.

Liu, F. T., Ting, K. M., & Zhou, Z. H. (2008). Isolation forest. IEEE International Conference on Data Mining, 413-422.

Breunig, M. M., Kriegel, H. P., Ng, R. T., & Sander, J. (2000). LOF: Identifying density-based local outliers. ACM SIGMOD Record, 29(2), 93-104.

Agrawal, R., & Srikant, R. (1994). Fast algorithms for mining association rules. Proceedings of VLDB Conference, 487-499.

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Van der Maaten, L., & Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9(11), 2579-2605.

Neslin, S. A., Gupta, S., Kamakura, W., Lu, J., & Mason, C. H. (2006). Defection detection: Measuring and understanding the predictive accuracy of customer churn models. *Journal of Marketing Research*, 43(2), 204-211.

- Harvard Business Review (2020). The Value of Keeping the Right Customers.
<https://hbr.org/2014/10/the-value-of-keeping-the-right-customers>
- GSMA Intelligence (2022). Global Mobile Trends 2022: Latin America Telecommunications Market. <https://www.gsmainelligence.com/>